

Project Results: AGA + Ouroboros

Дата среза: 20 июля 2026 года. Это канонический текстовый отчёт MVP; при экспорте в PDF его цифры нельзя менять независимо от `SUBMISSION-FACTS.json`.

1. AS IS: почему ручной governance не масштабируется

Architecture-as-Code PR нужно сверить с SEAF, ADR, диаграммами и архитектурными принципами. Ручная проверка зависит от загрузки архитектора, имеет неодинаковую глубину и создаёт повторные итерации из-за комментариев без точной ссылки на источник.

В Project Proposal приведён не production-замер, а сценарий: 30 PR в неделю по 50 минут дают 25 часов ручного review на блок из четырёх архитекторов. Полная формула, добавленные допущения и sensitivity находятся в `BUSINESS-EFFECT.md`.

2. TO BE: что меняет AGA

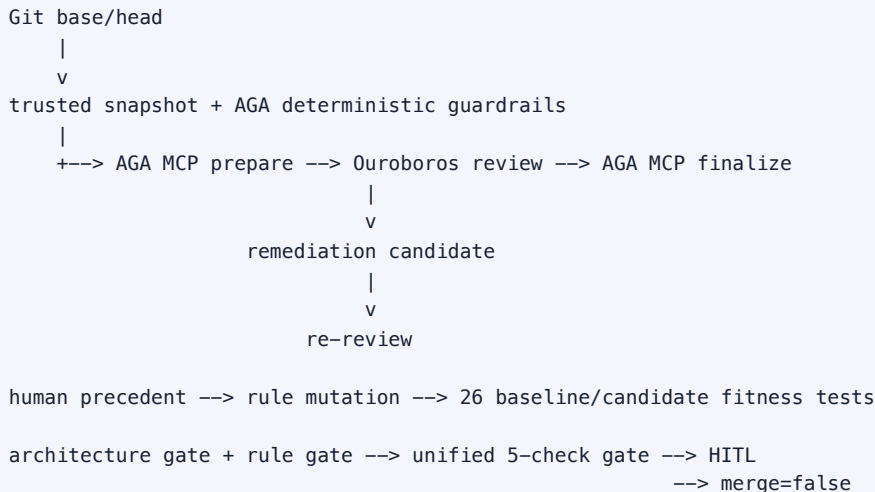
AGA принимает доверенные immutable `base / head` revisions, строит безопасный snapshot и возвращает интерпретируемое advisory-review:

- детерминированные SEAF, ADR и diagram guardrails;
- semantic review архитектурных принципов через Ouroboros и AGA MCP;
- severity, точный artifact/location, evidence и `source_ref`;
- fail-closed `incomplete`, если данных или надёжности недостаточно;
- локальный candidate patch и повторное review для поддержанного сценария;
- обязательный HITL: `blocker / major` не проходят автоматически, merge отсутствует.

3. Реализованные функции MVP

Функция	Реализованный результат
Architecture-as-Code review	SEAF-native snapshot, deterministic guardrails и semantic boundary
Ouroboros orchestration	Реальные review, remediation и re-review tasks с MCP receipts и cost
Ремедиация архитектуры	Минимальный patch для <code>SEAF-004</code> только по явно заданному <code>replaced_by</code>
Эволюция правил	Прецедент → candidate mutation → severity-aware fitness → локальный candidate
Проверка регрессий	26 materialized golden cases до и после candidate
Unified safety gate	Пять независимых checks; любое падение блокирует результат
Evidence	JSON, diff, manifests, SHA-256 и sanitization без secret/raw-provider payload
Публикация	Только локальный candidate; push, approve, auto-merge и merge отсутствуют

4. Архитектура решения



Граница доверия важнее конкретной модели: Ouroboros не получает произвольный filesystem path и не может сам применить или опубликовать candidate. AGA MCP валидирует revision, schema, evidence и итоговый verdict на стороне trusted host.

5. Demo E2E

Локальный бесплатный сценарий генерирует синтетический граф из 11 узлов и 9 потоков и затем параллельно выполняет два контура.

1. Architecture lane находит SEAF-004: поток ведёт в компонент со статусом eliminate.
2. Remediation меняет только to: demo.legacy_scoring на явно объявленный to: demo.scoring_v2.
3. Re-review подтверждает закрытие finding и отсутствие новых нарушений.
4. Rule lane сравнивает baseline и candidate на всех 26 golden cases.
5. Unified gate проверяет workspace, закрытие SEAF-004, 26 candidate outcomes, отсутствие rule-regressions и строгое улучшение.
6. Результат сохраняет evidence и требует человеческого review; merge не выполняется.

Запуск и проверка:

```
make demo-verify
make self-evolution-ui
```

После второй команды интерфейс доступен только на loopback-адресе `http://127.0.0.1:8090`.

6. Результаты на примерах

Архитектурный finding и remediation

В контролируемом real Ouroboros E2E review-before вернул request_changes_escalate, отдельная remediation task сформировала candidate, а re-review вернул advisory approve. Три task ID и расходы сохранены в `ouroboros-self-evolution-v1.json`. Суммарная зафиксированная стоимость трёх задач — 0.113183 USD; gate прошёл, но результат остался локальным candidate с обязательным HITL.

Эволюция правила и negative control

Baseline ошибочно блокировал согласованный DMZ batch-flow в pr-15. Узкое исключение, выведенное из подтверждённого прецедента, исправило только этот кейс. Опасный неконтролируемый flow pr-16 остался заблокированным.

Результат	Baseline	Candidate
Cases с точным finding-set и outcome	25/26	26/26
Precision	0.9524	1.0
Recall	1.0	1.0
Blocker recall	1.0	1.0
Weighted cost	2.0	0.0

Источник: frozen deterministic snapshot.

7. Метрики и measurement boundary

Одинаковые знаменатели нельзя смешивать в одну «общую точность».

Измерение	Результат	Что доказывает	Чего не доказывает
Deterministic rule fitness	25/26 → 26/26	Узкая mutation улучшает golden-корпус без регрессии	Качество LLM на новых PR
Controlled live self-evolution	3 real tasks, gate PASS, 0.113183 USD	Ouroboros/MCP review → remediation → re-review работает E2E	Broad semantic release
Development-v2	48 locked synthetic-public cases; human review pending ; series pre_measurement	Новый strict corpus/scorer и Git materialization готовы к независимой проверке	Model quality или release PASS
16-case fixture	16/16, release evidence=false	Scorer, corpus и gate plumbing	Качество модели
Исторический frozen real run	10/16; precision/recall/blocker recall 0.50/0.50/0.50 ; outcome 0.8125 ; unsafe approve 2	Честный результат старого freeze	Текущую release-готовность
Канонический trusted all-case result	not_run , 0 cases	PASS-only sentinel не подменён fixture/FAIL	Наличие release PASS

Старый frozen holdout раскрыт и не может использоваться повторно. Новый 48-case development-v2 создан и hash-locked, но независимый human review ещё pending , measurement series не frozen и платных прогонов не было. Для нового release claim нужны независимая проверка ground truth, пять стабильных development repeats, freeze и новый untouched holdout.

После human review и freeze development stability проверяется ровно на пяти distinct HMAC-attested captures с неизменными model/prompt/config/selection и внешним ключом серии. Бесплатный verifier заново скорит результаты, считает worst-case quality, approve/non-approve flapping, p95, tokens и cost; team budgets обязательны и не имеют выдуманных defaults:

Pinned Ouroboros v6.64.1 main loop не передаёт temperature , top_p или seed , поэтому sampling determinism не заявляется. Этот факт входит в secret-free config identity; расхождение повторов не может превратиться в approve через stability gate.

```
make verify-development-v2-series \  
  DEVELOPMENT_V2_SERIES_INPUTS="repeat-1.json repeat-2.json repeat-3.json repeat-4.json repeat-5.json" \  
  DEVELOPMENT_V2_ATTESTATION_KEY_FILE=<external-key-file> \  
  DEVELOPMENT_V2_MAX_P95_MS=<team-p95-budget-ms> \  
  DEVELOPMENT_V2_MAX_COST_USD=<team-cost-cap-usd>
```

8. Safety и ограничения

- Только `synthetic-public` данные разрешены во внешнем `model path`.
- Raw prompts, provider payloads, credentials и абсолютные локальные пути не сохраняются в `public evidence`.
- Missing context, schema error и invalid evidence должны завершаться `fail-closed`, а не `optimistic approve`.
- Ремедиация MVP поддерживает один ограниченный паттерн `SEAF-004`; цель берётся только из явного `replaced_by`.
- `Advisory approve` не является Bitbucket/GitHub approve и не запускает merge.
- Исторический broad semantic release gate — `FAIL`; нового trusted PASS пока нет.
- GitHub Actions закреплены полными commit SHA, базовый Docker image — manifest digest, Python wheels для CI/container — SHA-256, apt — датированный Debian snapshot. Эти pins проверяет `make project-results-check`; claim не распространяется на побитовую воспроизводимость произвольной host-системы.

9. Соответствие Project Proposal

Proposal обещал 13 demo PR, 15 systems и auto-approve. Фактический MVP использует 26 golden cases плюс отдельную 16-case semantic basket, генерирует 11-node demo graph и выдаёт только advisory approve без merge. Это расширение и изменение границ раскрыто построчно в [PROPOSAL-TRACEABILITY.md](#), а не скрыто заменой цифр.

10. Следующие шаги к production

1. Независимо проверить ground truth 48-case `development-v2`, frozen series и выполнить пять стабильных development-прогонов.
2. После freeze один раз выполнить новый untouched holdout и получить trusted all-case PASS без unsafe approve.
3. Провести Docker build rehearsal на машине с daemon и сохранить build provenance; immutable Actions/image/wheel/OS pins уже проверяются локально.
4. Выбрать root license, проверить clean clone в публичном репозитории и опубликовать immutable submission commit.
5. Подключить внутренние model/runtime, RBAC, secret store, audit и реальные Bitbucket/SEAF endpoints.
6. Измерить production baseline и TCO; не использовать proposal-сценарий как фактический ROI.

11. Статус артефактов подачи

- Публичный repository URL: **не опубликован**.
- Demo video URL: **не опубликован**.
- Локальный Project Results PDF: [AGA-Ouroboros-Project-Results.pdf](#); public URL пока **не опубликован**, а этот Markdown остаётся каноническим источником.
- Project Proposal: [Project_Proposal_AGA_SberAIHack.pdf](#).
- Презентация: [AGA-Ouroboros-Project-Results.pptx](#), редактируемый Markdown: [PRESENTATION.md](#), speaker outline: [PRESENTATION-OUTLINE.md](#).
- Сценарий видео: [DEMO-VIDEO-SCRIPT.md](#).